

# Lucrare laborator

Componenta b)

Autor: Cuciurean Emilian-Petruț

Grupa: 232/2

April 23, 2026

## 1 Analiza problemei (Articole reprezentative)

### 1.1 Deepti Sisodia & Dilip Singh Sisodiab (2018).

*Prediction of diabetes using classification algorithms.* [1]

- **Contribuția principală:** Autorii propun un sistem de diagnosticare timpurie a diabetului testând trei algoritmi clasici: Naive Bayes, Support Vector Machine (SVM) și Decision Tree, aplicați exclusiv pe setul de date Pima Indians Diabetes Database (PIDD).
- **Sumar al rezultatelor:** Performanța algoritmilor a fost evaluată prin Acuratețe, Precizie, Recall curbe ROC și scor F1. Algoritmul Naive Bayes a obținut cea mai mare acuratețe (76.30%, ROC = 0.819), urmat de Decision Tree (73.82%) și SVM (65.10%).
- **Limitări ale abordării:** Deși studiul validează utilitatea ML pe setul Pima, acuratețea generală se plafonează la aproximativ 76%. Acest lucru sugerează că modelele simple (single-classifiers), fără o tehnică avansată de optimizare a hiperparametrilor, au o limită de învățare pe acest set de date.

### 1.2 Mohammad Sahebbonar, Mehrzad Gholampour Dehaki, Mohammad Hassan Kazemi-Galougahi, Saeed Soleiman-Meigooni (2022).

*A Comparison of Three Research Methods: Logistic Regression, Decision Tree, and Random Forest to Reveal Association of Type 2 Diabetes with Risk Factors and Classify Subjects in a Military Population.* [2]

- **Contribuția principală:** Studiul compară direct eficiența a trei algoritmi specifici (Regresia Logistică, Arborii de Decizie și Random Forest) pentru clasificarea pacienților cu diabet de tip 2, concentrându-se pe importanța factorilor de risc. Datele provin de la 3.661 de militari iranieni. O contribuție importantă a articolului este aplicarea explicită a tehnicii SMOTE (oversampling) pe setul de antrenare (70% / 30% split) pentru a combate dezechilibrul claselor (doar 3% cazuri pozitive de diabet, ). Aceasta îmbunătățește performanța modelelor, reducând supraajustarea (overfitting).
- **Sumar al rezultatelor:** Random Forest (1000 de arbori) a obținut cea mai bună performanță: acuratețe 94.4%, sensibilitate 100%, specificitate 94.2% și Area Under Curve (AUC) 97.1%. Decision Tree a atins AUC 77.1%, iar Regresia Logistică AUC 73.8% ambele semnificativ inferioare RF. Analiza importanței variabilelor în RF a arătat că vârsta (100%) și Indicele de Masa Corporală (IMC) (51.3%) sunt cei mai importanți predictorii, confirmat și de arborele de decizie care folosește aceste două variabile ca noduri principale.

- **Limitări ale abordării:** Fiind aplicat pe o populație cu un profil specific (militară), modelul necesită validare încrucișată pe alte demografii (cum ar fi setul Pima, care conține exclusiv femei, din mediu normal de viață) pentru a-și demonstra capacitatea generală de predicție.

### 1.3 Zeyu Zhang, Khandaker Asif Ahmed, Md Rakibul Hasan, Tom Gedeon and Md Zakir Hossain (2024).

*DiabetesNet: A Deep Learning Approach to Diabetes Diagnosis* [3]

- **Contribuția principală:** Autorii introduc o arhitectură avansată bazată pe o Rețea Neurală cu Propagare Înapoi (BPNN) cu 3 straturi ascunse (64-32-16 neuroni) normalizare batch și optimizator Adam, evaluat pe PIDD și două alte seturi. Pipeline-ul include undersampling al clasei majoritare (500 → 268 instanțe), standardizare z-score și optimizare de hiperparametri prin grid search cu validare încrucișată cu 5 pliuri (80% antrenare, 20% testare)
- **Sumar al rezultatelor:** Prin augmentarea datelor și utilizarea Deep Learning, studiul raportează o acuratețe State-of-the-Art (SOTA) impresionantă de 89.81% pe setul Pima (sensibilitate 89.29%, specificitate 90.38%) , depășind cu mult limitele algoritmilor ML clasici.
- **Limitări ale abordării:** Modelul BPNN este o cutie neagră: nu oferă reguli explicite de decizie, limitând adoptarea în contextul clinic unde medicii necesită justificarea predicției. Tehnica de undersampling folosită elimină 232 de instanțe reale din setul original, reducând datele de antrenare de la 768 la 536. O alternativă superioară ar fi SMOTE, care generează instanțe sintetice fără a elimina date reale.

## 2 Soluția propusă

### • Scurtă descriere / schemă:

Soluția propusă constă într-un pipeline de ML pentru clasificare binară pe setul PIDD, structurat în următoarele etape:

1. **Preprocesarea datelor.** Valorile zero imposibil biologic (glucoză, tensiune arterială, IMC, grosime pli cutanat, insulină) se înlocuiesc cu date normalizate și standardizate.
  2. **Echilibrarea claselor.** Aplicarea SMOTE exclusiv pe setul de antrenare, după split.
  3. **Împărțirea datelor.** 80% antrenare / 20% testare.
  4. **Antrenarea modelelor.** Regresia Logistică (ca model statistic de referință), Decision Tree (pentru interpretabilitate clinică maximă) și Random Forest (pentru combaterea fenomenului de overfitting).
  5. **Evaluarea.** Matrice de Confuzie, Acuratețe, Precizie, Recall, F1, AUC-ROC. Validare încrucișată cu 5 pliuri.
  6. **Interfața** Aplicație web cu Streamlit pentru Demo (Componenta d).
- **Motivație** Deși cercetările recente (precum DiabetesNet) ating acurateți de aproape 90% folosind Deep Learning, în domeniul medical "transparența" deciziei este critică. Soluția propusă se bazează pe algoritmi capabili să genereze reguli ușor de înțeles de către medici (ex: Dacă Glicemia >125 și BMI >30 → Risc Ridicat). Mai mult, setul de date având doar 768 de instanțe, aplicarea unor rețele neuronale complexe ar fi ineficientă computațional și ar duce rapid la supraînvățare (overfitting).

- **Plan de lucru**

**Setul de date.** *Pima Indians Diabetes Database* (PIDD), disponibil public pe Kaggle [4]. 768 instanțe, 8 attribute numerice, variabilă țintă binară (0 = sănătos, 1 = diabetic). Feature-ul **Pregnancies** este exclus conform Componentei (a).

**Tehnologii.** `Python`, `pandas`, `numpy` (procesare date), `scikit-learn`, `imbalanced-learn` (SMOTE), `Streamlit` (interfață web Demo) → vom integra cel mai performant model dintre cele trei (probabil Random Forest) într-o interfață web minimală și interactivă folosind biblioteca Streamlit, unde utilizatorul va putea introduce datele medicale manual și va primi o predicție instantanee..

**Evaluarea performanței.**

- Matrice de Confuzie (TP, FP, TN, FN)
- Acuratețe:  $A = (TP + TN)/N$
- Precizie:  $P = TP/(TP + FP)$
- Recall (Sensibilitate):  $R = TP/(TP + FN)$
- Scor F1:  $F_1 = 2 \cdot P \cdot R/(P + R)$

## References

- [1] Deepti Sisodia and Dilip Singh Sisodia. Prediction of diabetes using classification algorithms. *Procedia Computer Science*, 132:1578–1585, 2018. <https://doi.org/10.1016/j.procs.2018.05.122>.
- [2] Mohammad Sahebbonar, Mehrzad Gholampour Dehaki, Mohammad Hassan Kazemi-Galougahi, and Saeed Soleiman-Meigooni. A comparison of three research methods: Logistic regression, decision tree, and random forest to reveal association of type 2 diabetes with risk factors and classify subjects in a military population. *Journal of Archives of Military Medicine*, 10(2):Article no. e118525, 2022. <https://doi.org/10.5812/jamm-118525>.
- [3] Zeyu Zhang, Khandaker Asif Ahmed, Md Rakibul Hasan, Tom Gedeon, and Md Zakir Hossain. A deep learning approach to diabetes diagnosis. In *Asian Conference on Intelligent Information and Database Systems*, pages 87–99. Springer, 2024. <https://steve-zeyu-zhang.github.io/DiabetesDiagnosis>.
- [4] UCI Machine Learning Repository / Kaggle. Pima indians diabetes database, 2016. <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>. Accesat: Aprilie 2026.