

Lucrare laborator

Componenta c)

Autor: Cuciurean Emilian-Petruț

Grupa: 232/2

May 20, 2026

1 Rezultate experimentale

1.1 Setul de date

Setul de date utilizat este **Pima Indians Diabetes Database (PIDD)**, un set de date real și public, disponibil pe platforma Kaggle¹. Acesta conține 768 de înregistrări colectate de la femei din comunitatea Pima, cu vârsta de minimum 21 de ani. Variabila țintă (*Outcome*) este binară: **0** (sănătos) sau **1** (predispus la diabet), distribuția originală fiind de 500 cazuri negative și 268 cazuri pozitive, ceea ce introduce un dezechilibru al claselor de aproximativ 65% / 35%.

Setul conține inițial 9 coloane: *Pregnancies*, *Glucose*, *BloodPressure*, *SkinThickness*, *Insulin*, *BMI*, *DiabetesPedigreeFunction*, *Age* și *Outcome*. Feature-ul *Pregnancies* a fost eliminat deoarece modelul trebuie să fie generalizabil ambelor sexe.

1.2 Preprocesări

Preprocesarea datelor a urmat o logică strictă pentru a evita *data leakage* și pentru a corecta anomaliile biologice prezente în set.

1. Înlocuirea zerourilor biologice imposibile. Cinci coloane (*Glucose*, *BloodPressure*, *SkinThickness*, *Insulin*, *BMI*) conțin valori de 0 care sunt imposibile fiziologic — glucoza 0 sau tensiunea 0 înseamnă practic date lipsă înregistrate incorect. Aceste valori au fost înlocuite cu NaN înainte de orice împărțire a datelor.

2. Împărțirea datelor (80% / 20%). Setul a fost împărțit în 80% antrenare (614 înregistrări) și 20% testare (154 înregistrări), folosind *stratified split* — proporția claselor 0/1 este păstrată identică în ambele seturi. Această decizie este importantă: dacă am fi împărțit aleatoriu, am fi putut obține un set de test dezechilibrat care să distorsioneze metricile.

3. Imputarea valorilor lipsă cu mediana. Valorile NaN au fost înlocuite cu **mediana calculată exclusiv pe setul de antrenare**, aplicată ulterior și pe test. Logica este simplă: mediana este robustă la valori extreme (spre deosebire de medie), iar calcularea ei doar pe train asigură că informația din test nu influențează preprocesarea.

¹<https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>

4. **Standardizarea (StandardScaler).** Fiecare feature a fost standardizat prin formula:

$$X_{scaled} = \frac{X - \mu_{train}}{\sigma_{train}} \quad (1)$$

unde μ_{train} și σ_{train} sunt media și deviația standard calculate **pe setul de antrenare**. Pe setul de test s-a aplicat doar **transform**, nu și calculul statisticilor (**fit**). Standardizarea este esențială pentru *Logistic Regression*, al cărei gradient descendent este sensibil la scara valorilor; fără ea, un feature cu valori mari (ex: Insulin: 10–900) ar domina nejustificat față de unul cu valori mici (ex: DiabetesPedigreeFunction: 0.05–2.5). Pentru *Random Forest* și *Decision Tree*, standardizarea nu afectează performanța (arborii fac comparații relative), dar a fost aplicată uniform pentru consistența pipeline-ului.

5. **Echilibrarea claselor cu SMOTE.** Dezechilibrul 65% / 35% al claselor a fost corectat prin **SMOTE** (*Synthetic Minority Over-sampling Technique*), aplicat **exclusiv pe setul de antrenare**, după standardizare. SMOTE generează instanțe sintetice ale clasei minoritare (diabetici) prin interpolare în spațiul k-vecinilor apropiați, aducând numărul de instanțe la egalitate. Aplicarea sa **doar pe train** este critică: setul de test trebuie să reflecte distribuția reală a populației, altfel metricile de evaluare ar fi optimiste și nerealiste de bune.

1.3 Metrici de evaluare

Performanța modelelor a fost cuantificată prin cinci metrici complementare, calculate pe setul de test:

- **Acuratețe (Accuracy)** — proporția predicțiilor corecte din totalul cazurilor:

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (2)$$

- **Precizie (Precision)** — din toate cazurile prezise ca pozitive (diabetici), câte sunt cu adevărat pozitive. Penalizează fals-pozitivele:

$$Prec = \frac{TP}{TP + FP} \quad (3)$$

- **Recall (Sensibilitate)** — din toate cazurile pozitive reale, câte au fost detectate corect. Penalizează fals-negativele (pacienți bolnavi clasificați ca sănătoși):

$$Rec = \frac{TP}{TP + FN} \quad (4)$$

- **Scorul F1** — media armonică dintre Precizie și Recall, utilă când clasele sunt dezechilibrate:

$$F1 = 2 \cdot \frac{Prec \cdot Rec}{Prec + Rec} \quad (5)$$

- **ROC-AUC** — aria de sub curba ROC (True Positive Rate vs. False Positive Rate la diferite praguri de clasificare). O valoare de 1.0 indică un model perfect, 0.5 indică clasificare aleatoare. Este metrika principală de selecție a modelului final, deoarece este robustă la dezechilibrul claselor.

În contextul medical al acestui proiect, **Recall-ul** este metrika cu cea mai mare importanță practică: un fals-negativ (pacient diabetic clasificat ca sănătos) este mult mai periculos decât un fals-positiv (pacient sănătos trimis la investigații suplimentare).

1.4 Metodologie de antrenare și evaluare

1.4.1 Paradigma de învățare și împărțirea datelor

Problema abordată este una de **clasificare binară supervizată** — modelele învață dintr-un set etichetat (Outcome: 0 sau 1) și prezic clasa pentru date nevăzute.

Datele au fost împărțite în **80% antrenare** (614 înregistrări) și **20% testare** (154 înregistrări). Nu s-a utilizat un set de validare separat; în schimb, **validarea încrucișată cu 5 pliuri** pe setul de antrenare joacă rolul setului de validare, permițând compararea modelelor fără a „consuma” datele de test. Setul de test rămâne complet izolat și este folosit o singură dată, la evaluarea finală.

1.4.2 Descrierea modelelor, funcții de cost și hiperparametri

Logistic Regression. Model liniar de referință (*baseline*). Calculează probabilitatea de apartenență la clasa 1 prin funcția sigmoidă aplicată combinației liniare a feature-urilor:

$$\hat{y} = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}} \quad (6)$$

Funcția de cost este Binary Cross-Entropy (Log Loss), minimizată prin gradient descent:

$$L = -\frac{1}{n} \sum_{i=1}^n [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (7)$$

Hiperparametri: `max_iter=1000` (garantează convergența pe datele standardizate), `C=1.0` (regularizare L2 implicită, penalizează coeficienți prea mari pentru a preveni overfitting-ul).

Decision Tree. Model bazat pe arbore binar care partajează spațiul feature-urilor prin reguli de decizie succesive (ex: *Dacă Glucose > 127 și BMI > 29.9 ⇒ Diabetic*). La fiecare nod, algoritmul caută split-ul care minimizează **impuritatea Gini** a celor doi copii rezultați:

$$Gini = 1 - \sum_{k=0}^1 p_k^2 \quad (8)$$

unde p_k este proporția instanțelor din clasa k în nodul curent. O valoare Gini de 0 indică un nod pur (o singură clasă), iar 0.5 indică un nod complet amestecat. Optimizarea este **greedy** — fiecare nod este optimizat local, fără backtracking global.

Hiperparametri: `max_depth=5` (limitează adâncimea arborelui pentru a preveni overfitting-ul), `criterion='gini'`, `random_state=42`.

Random Forest. Ansamblu de 100 de arbori de decizie, fiecare antrenat pe un **bootstrap sample** (subset aleatoriu cu înlocuire din datele de antrenare). La fiecare split, fiecare arbore consideră doar $\sqrt{p}$ feature-uri aleatorii ($p = 7 \Rightarrow \approx 2-3$ feature-uri per split), introducând diversitate suplimentară între arbori. Predicția finală este **votul majoritar** al celor 100 de arbori:

$$\hat{y} = \text{majority_vote}(\hat{y}_1, \hat{y}_2, \dots, \hat{y}_{100}) \quad (9)$$

Deoarece fiecare arbore vede date și feature-uri diferite, erorile lor sunt necorrelate — media voturilor anulează zgomotul individual și reduce varianța față de un singur arbore, combătând overfitting-ul fără a crește bias-ul.

Hiperparametri: `n_estimators=100`, `max_features='sqrt'` (implicit), `random_state=42`, `n_jobs=-1` (paralelizare pe toate core-urile disponibile).

1.4.3 Validarea încrucișată

Pe lângă evaluarea pe setul de test, s-a efectuat o **validare încrucișată stratificată cu 5 pliuri** (*5-fold Stratified CV*) pe setul de antrenare, pentru a verifica stabilitatea modelelor și a detecta eventualele semne de overfitting. Această abordare împarte setul de antrenare în 5 subseturi egale, antrenând modelul pe 4 dintre ele și validând pe al 5-lea, rotind procesul de 5 ori și calculând media și deviația standard a metricilor.

1.5 Rezultate efective și analiză

1.5.1 Rezultate pe setul de test

Table 1: Metrici de performanță pe setul de test (20% din date)

Model	Accuracy	Precision	Recall	F1	ROC-AUC
Logistic Regression	0.7013	0.5667	0.6296	0.5965	0.7970
Decision Tree	0.7792	0.6613	0.7593	0.7069	0.7924
Random Forest	0.7338	0.6032	0.7037	0.6496	0.8121

1.5.2 Rezultate validare încrucișată (5-fold CV)

Table 2: Metrici de performanță — Validare încrucișată stratificată cu 5 pliuri (medie $\pm$ std)

Model	Accuracy	Recall	F1	ROC-AUC
Logistic Regression	0.7475 ± 0.0219	0.7125 ± 0.0647	0.7368 ± 0.0360	0.8392 ± 0.0177
Decision Tree	0.7525 ± 0.0219	0.8375 ± 0.0524	0.7713 ± 0.0238	0.8123 ± 0.0192
Random Forest	0.8062 ± 0.0274	0.8400 ± 0.0470	0.8122 ± 0.0291	0.8951 ± 0.0230

1.5.3 Analiza rezultatelor

Comparație între modele pe setul de test. *Decision Tree* obține cea mai mare acuratețe (77.92%) și cel mai bun F1 (0.7069) pe setul de test. Totuși, *Random Forest* este ales ca model final datorită celui mai mare **ROC-AUC (0.8121)**, care este metrica cea mai robustă în prezența dezechilibrului de clase. Un ROC-AUC mai mare înseamnă că modelul diferențiază mai bine între clase la orice prag de clasificare, nu doar la pragul implicit de 0.5.

Validarea încrucișată confirmă superioritatea Random Forest. Rezultatele CV arată că *Random Forest* domină: AUC mediu de 0.8951 ± 0.023 , față de 0.8392 (LR) și 0.8123 (DT). Deviațiile standard relativ mici indică un model stabil, care nu depinde excesiv de împărțirea particulară a datelor. De remarcat că performanțele CV sunt sistematic mai bune decât cele pe test — aceasta se datorează faptului că CV-ul se face pe setul de antrenare (deja SMOTE-izat și echilibrat), în timp ce testul reflectă distribuția reală, dezechilibrată, a claselor.

Analiza matricilor de confuzie. Din perspectiva contextului medical, cel mai relevant indicator este numărul de **fals-negative** (pacienți diabetici clasificați ca sănătoși):

- Logistic Regression: **20 FN** (din 54 cazuri pozitive reale) [1a]
- Decision Tree: **13 FN** — cel mai mic număr de cazuri ratate [1b]

- Random Forest: **16 FN** [1c]

Decision Tree detectează cel mai bine cazurile pozitive (Recall = 0.7593), ceea ce îl face cel mai sigur clinic în această privință, deși Random Forest rămâne superior ca diferențiere globală (AUC).

Importanța feature-urilor. [3] Graficul de importanță a feature-urilor din Random Forest arată că **Glucose** este de departe cel mai important predictor (≈ 0.28), urmat de **BMI** (≈ 0.175) și **Age** (≈ 0.14). Aceasta este consistent cu literatura medicală: hiperglicemia este criteriul diagnostic principal al diabetului, iar obezitatea și vârsta sunt factori de risc majori. *BloodPressure* și *SkinThickness* contribuie cel mai puțin, ceea ce sugerează că ar putea fi eliminați într-o versiune viitoare a modelului fără pierdere semnificativă de performanță.




Figure 1: Comparația matricilor de confuzie pentru cele trei modele testate




Figure 2: Curbele ROC pentru cele trei modele — comparație vizuală




Figure 3: Importanța feature-urilor calculată prin reducerea impurității Gini în Random Forest