



Faculty of Mathematics and Computer Science

Tehnici de realizare a sistemelor inteligente (TRSI 2026)

Sistem Inteligent pentru Predicția Riscului de Diabet

Cuciurean Emilian-Petruț

*Department of Computer Science, Babes-Bolyai University
1, M. Kogalniceanu Street, 400084, Cluj-Napoca, Romania
E-mail: emicuciu@gmail.com*

Abstract

Diabetul zaharat este o boală cronică caracterizată prin hiperglicemie, rezultată din defecte în secreția de insulină, care poate duce la complicații severe precum boli cardiovasculare, insuficiență renală, pierderea permanentă a vederii etc., în cazul în care nu este diagnosticată sau tratată corect. Conform morbidității crescute observate în ultimii ani, se estimează că până în anul 2040 populația globală a pacienților diabetici va atinge aproximativ 642 de milioane, de unde rezultă faptul că unul din zece adulți va suferi de această boală. [10]. Acest raport de cercetare dorește să amplifice importanța depistării rapide și precise a diabetului, pentru pacienții (pre-diabetici) predispuși la acest risc, în general oameni supraponderali, cu simptome cum ar fi oboseala accentuată sau setea excesivă. Abordarea problemei este o analiză comparativă a metodelor de clasificare prin învățare automată asupra setului de date Pima Indians Diabetes Database (PIDD), utilizând trei algoritmi de învățare supervizată: Logistic Regression, Decision Tree, Random Forest. Pentru a asigura o generalizare fiabilă și pentru a reduce varianța performanței, articolul susține utilizarea k-fold cross-validation. Performanța acestor algoritmi este evaluată folosind Acuratețe (Accuracy), Precizie (Precision), Sensibilitate (Recall), F1-Score. Se pune accent pe **Recall** ca indicator principal de performanță pentru a minimiza rezultatele fals negativ care pot pune viața pacientului în pericol. Rezultatele sintetizate din literatură relevă faptul că algoritmul Random Forest are performanță per-total mai bună față de ceilalți algoritmi. Abordările de tip deep-learning au dovedit cea mai mare acuratețe 89.81% pe PIDD (DiabetesNet) [9], dar nu destul de sigure pentru domeniul clinic precum abordările transparente precizate anterior, care oferă suport decizional vizibil și explicabil, în ciuda unor scoruri mai mici.

© 2026 .

Keywords:

Diabet zaharat, Logistic Regression, Decision Tree, Random Forest, SMOTE, Class Imbalance, Pima Indians Dataset, Clasificare Binară, Recall

1. Introducere

Diabetul este o afecțiune care afectează capacitatea organismului de a produce și utiliza hormonul numit insulină, ceea ce face ca metabolismul carbohidraților să devină anormal și duce la creșterea nivelului de glucoză din sânge.

© 2026 .

În general, o persoană care suferă de diabet se confruntă cu un nivel ridicat al zahărului în sânge (hiperglicemie). Setea accentuată, foamea intensă și urinarea frecventă sunt câteva dintre simptomele timpurii cauzate de această creștere a glicemiei.[8]. Numeroase complicații severe pot apărea dacă boala rămâne netratată, printre care afecțiunile cardiovasculare (precum infarctul miocardic), insuficiența renală cronică și pierderea vederii [3]. Procedurile clinice tradiționale pentru diagnosticare implică teste de sânge riguroase, analize de laborator costisitoare și vizite repetate la medic. Identificarea timpurie rămâne, totuși, singurul remediu eficient pentru a preveni intensificarea bolii. În acest context, Inteligența Artificială și tehnicile de Învățare Automată oferă o alternativă modernă, permițând dezvoltarea unor sisteme de screening care pot analiza rapid date medicale de rutină, asistând medicii în procesul decizional.

Scopul principal al acestui articol este de a realiza o evaluare comparativă a trei algoritmi de clasificare interpretabili, de tip „white-box” (Regresia Logistică, Arborele de Decizie și Random Forest), pentru predicția riscului de diabet. Modelele sunt analizate folosind setul de date public *Pima Indians Diabetes Database* (PIDD). O atenție deosebită este acordată etapei de preprocesare, unde se subliniază necesitatea aplicării tehnicii SMOTE (*Synthetic Minority Over-sampling Technique*) pentru a corecta dezechilibrul inerent al datelor clinice. Performanța modelelor va fi analizată punând accent pe metrica *Recall*, având ca obiectiv critic minimizarea numărului de rezultate fals-negative.

Secțiunea 2 prezintă importanța practică a temei și domeniile de aplicare în medicină. Secțiunea 3 descrie setul de date PIDD și detaliază metodele de preprocesare a datelor. Secțiunea 4 expune fundamentul teoretic al algoritmilor de clasificare folosiți. Secțiunea 5 oferă o analiză a rezultatelor recente din literatura de specialitate. Secțiunea 6 prezintă o discuție critică a abordărilor analizate, iar Secțiunea 7 concluzionează lucrarea și propune direcții viitoare de cercetare.

2. Importanța Temei și Domenii de Aplicare

Diabetul zaharat nu reprezintă doar o criză de sănătate publică, ci și o povară economică masivă la nivel global. Costurile asociate cu tratamentul pe termen lung, spitalizările frecvente și gestionarea complicațiilor severe (cum ar fi amputațiile sau dializa) pun o presiune enormă pe bugetele sistemelor de sănătate. Din perspectivă clinică, screening-ul și identificarea pacienților aflați în faza de prediabet sunt pași esențiali pentru sănătatea oamenilor [3]. Prin urmare, automatizarea procesului de diagnosticare devine o necesitate practică.

Implementarea tehnicilor de Învățare Automată în domeniul medical deschide multiple direcții de aplicare. Un prim domeniu major este reprezentat de Sistemele de Suport Decizional Clinic (CDSS) din spitale și policlinici. În aceste medii, un model ML poate acționa ca un asistent virtual pentru medic. Introducând datele de rutină ale pacientului (vârstă, indice de masă corporală, nivelul glucozei etc.), sistemul poate genera instantaneu o probabilitate de risc, crescând productivitatea și susținând deciziile medicului.

Un alt domeniu de aplicare cu o creștere exponențială este Telemedicina și monitorizarea bazată pe Internet of Things (IoT). Odată cu avansul tehnologiilor portabile (wearables) și al senzorilor medicali, datele pacienților pot fi colectate de la distanță. Așa cum sugerează studii recente, modelele de clasificare pot fi integrate în aplicații mobile sau platforme cloud IoT pentru a monitoriza continuu pacienții din zone rurale sau defavorizate, oferind predicții în timp real fără a necesita deplasarea fizică la o clinică [3].

Din acest motiv, prezenta lucrare se concentrează pe algoritmi interpretabili, cunoscuți și sub denumirea de modele „white-box”. Acești algoritmi permit extragerea unor reguli medicale clare, de tip cauză-efect (de exemplu: „*Dacă nivelul glucozei este > 125 mg/dL și indicele BMI este > 30, atunci pacientul prezintă risc ridicat*”). Această transparență este fundamentală pentru adoptarea pe scară largă a sistemelor inteligente în mediul spitalicesc, garantând că decizia finală rămâne întotdeauna responsabilitatea medicului.

3. Setul de Date și Preprocesare

3.1. Baza de Date *Pima Indians Diabetes* (PIDD)

Această lucrare se bazează pe *Pima Indians Diabetes Database* (PIDD),colectat de National Institute of Diabetes and Digestive and Kidney Diseases (NIDDK). Setul cuprinde datele medicale de la 768 de pacienți de sex feminin, cu vârsta de cel puțin 21 de ani, de origine amerindiană (aparținând populației native Pima din Arizona, SUA). Variabila

țință (Outcome) este binară: 1 = persoană cu diabet (268 instanțe, 34.9%), 0 = persoană sănătoasă (500 instanțe, 65.1%).

Setul de date conține 8 atribute medicale. O descriere detaliată a acestor atribute, alături de distribuția lor statistică (Media, Deviația Standard și Domeniul de valori), este prezentată în Tabelul 1.¹

Table 1. Descrierea Atributelor PIDD și statistici descriptive [3]

Atribut	Descriere	Medie	Deviație Std.	Domeniu (Range)
Pregnancies	Numărul de sarcini	3.85	3.37	0 – 17
Glucose	Concentrația de glucoză în plasmă la 2 ore (Test oral)	121	32	0 – 199
BloodPressure	Tensiunea arterială diastolică (mm Hg)	69.1	19.3	0 – 122
SkinThickness	Grosimea pliului cutanat triceps (mm)	20.5	15.9	0 – 99
Insulin	Insulina serică la 2 ore (μ U/ml)	79.8	115	0 – 846
BMI	Indicele de Masă Corporală (greutate în kg / (înălțime în m) ²)	32	7.88	0 – 67
Diabetes Pedigree Function	Funcția de ereditate a diabetului (risc genetic)	0.47	0.33	0.078 – 2.4
Age	Vârsta pacientului	33.2	11.8	21 – 81
Outcome	Class variable (0 or 1)	0.35	0.48	True/False

3.2. Valorile de Zero Implauzibile

O problemă documentată a setului PIDD este prezența valorilor de zero în atribute unde acest lucru este imposibil din punct de vedere fiziologic (ex. Glucoză, Tensiune arterială, BMI). Acestea nu sunt măsurători reale, ci valori lipsă mascate. Tratarea acestor anomalii împarte literatura de specialitate în două direcții distincte:

1. **Abordarea prin Ștergere (Listwise Deletion):** Cercetători precum Zou et al. [10] au optat pentru eliminarea completă a înregistrărilor care conțineau valori de zero, reducând setul original de la 768 la doar 392 de instanțe. Această abordare conservatoare duce la o pierdere masivă de informație statistică (aproape 50% din date) și reduce sever capacitatea de generalizare a modelelor.
2. **Abordarea prin Imputare:** În contrast, Hasan et al. [5] au demonstrat că păstrarea instanțelor și corectarea lor crește semnificativ performanța predictivă. Metodologia lor a constat în eliminarea valorilor outliers prin metoda intervalului intercuartilic (IQR), urmată de imputarea golurilor folosind media aritmetică.

3.3. Dezechilibrul Claselor: Undersampling vs. SMOTE

Distribuția inegală a claselor (500 pacienți sănătoși vs. 268 pacienți bolnavi → 65.1% vs 34.9%) reprezintă un obstacol major. Așa cum observă Zhang et al. [9], algoritmi de clasificare sunt proiectați cu presupunerea că datele sunt echilibrate. Antrenarea pe un set dezechilibrat induce un *bias* (o părtinire) către clasa majoritară, generând un număr mare de erori fals-negative (pacienți bolnavi nediagnosticsați) și o sensibilitate scăzută. Studii independente de referință, precum cele realizate de Sisodia et al. [8] și Shafi & Ansari [7], ilustrează perfect această problemă: aplicat pe date brute, modelul SVM eșuează drastic. În cazul studiului Sisodia et al., SVM a clasificat toți cei 268 de pacienți diabetici ca fiind sănătoși, raportând totuși o acuratețe înșelătoare de 65.10%, respectiv Shafi et al. 63.10% din aceleași cauze legate de dezechilibru.

Pentru rezolvarea acestei probleme, literatura oferă din două perspective:

1. **Sub-eșantionarea (Undersampling):** Zhang et al. [9] au ales să echilibreze datele prin eliminarea aleatorie a instanțelor din clasa majoritară până la atingerea dimensiunii clasei minoritare. Rezultatul a fost un set restrâns de 268 vs. 268 instanțe. Deși previne *bias*-ul de antrenare, această decizie a însemnat aruncarea a 232 de dosare medicale valide, o pierdere nejustificată pe un set de date deja limitat ca volum.

¹ Diabetes Pedigree Function (DPF) este o valoare numerică utilizată în modelele de Machine Learning pentru a estima riscul genetic de diabet, luând în calcul istoricul familial și gradul de rudenie.

2. **Supra-eșantionarea (SMOTE):** Tehnica SMOTE propusă de Chawla et al. [4] este superioară în acest context. În loc să elimine date reale din clasa pacienților sănătoși, SMOTE păstrează toate cele 500 de instanțe negative și generează instanțe pozitive *sintetice* până la egalarea claselor. Pentru a asigura corectitudinea evaluării, algoritmul SMOTE trebuie aplicat *exclusiv* asupra setului de antrenare (Train Set), după realizarea separării datelor, pentru a nu contamina setul de testare.

Lucrarea de față adoptă paradigma imputării pentru a maximiza volumul de date disponibile, însă se propune utilizarea mediane în locul mediei aritmetice. Datele clinice, cum ar fi nivelul insulinei (care prezintă variații uriașe, ajungând până la $846 \mu\text{U/ml}$, conform Tabelului 1), au o distribuție puternic asimetrică. În astfel de cazuri, media aritmetică este vulnerabilă, fiind trasă în sus de valorile extreme izolate. Mediana, reprezentând valoarea de mijloc a șirului ordonat, este o metrică care ignoră aceste extreme. Astfel, imputarea cu mediana garantează o reconstrucție mult mai realistă și sigură a profilului fiziologic al pacientului, evitând introducerea unor valori fals-ridicate în datele de antrenare.

4. Metode de Clasificare

Această secțiune prezintă fundamentul teoretic al celor trei algoritmi de clasificare evaluați în lucrare, cu accent pe proprietățile lor de interpretabilitate relevante pentru contextul medical.

4.1. Regresia Logistică (Logistic Regression)

Regresia Logistică estimează probabilitatea ca un pacient să dezvolte diabet, generând un scor între 0 și 1. Trecerea de la o combinație de factori de risc la o decizie binară este realizată prin intermediul funcției logistice (sigmoide):

$$P(y = 1 \mid \mathbf{x}) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^p \beta_i x_i)}} \quad (1)$$

- $P(y = 1 \mid \mathbf{x})$: Probabilitatea ca variabila țintă să fie 1 (diabetic) pentru vectorul de intrare $\mathbf{x}$.
- e : Constanta lui Euler (baza logaritmului natural, ≈ 2.718).
- β_0 : Interceptul sau termenul de bias (pondera bazei fără influența atributelor).
- β_i : Coeficienții de regresie care determină magnitudinea și direcția influenței fiecărui atribut x_i .
- p : Numărul total de atribute clinice (caracteristici).

Principalul avantaj al acestui model este claritatea cu care indică impactul fiecărui factor clinic, coeficienții β_i arată cât de mult contribuie fiecare atribut la risc. De exemplu, Sahebbonar et al. [6] raportează că fiecare an adăugat la vârsta pacientului crește probabilitatea de diabet cu 16%, iar fiecare unitate de BMI crește riscul cu 12%. Limitele principale: LR presupune că granița dintre clase este o linie dreaptă necesitând standardizare z-score înainte de training. Algoritmii bazați pe arbori (DT, RF) nu au această limitare.

4.2. Arborele de Decizie (Decision Tree)

Un Arbore de Decizie (DT) împarte înregistrările în subgrupuri, punând întrebări de tip „if-then” (ex. „glucoza este > 127 ?”). La fiecare nod, se alege atributul și pragul care separă cel mai bine clasele, cel mai frecvent măsurat prin impuritatea Gini:

$$G_m = 1 - \sum_{c \in \{0,1\}} p_{mc}^2 \quad (2)$$

- G_m : Impuritatea Gini la nodul m .
- c : Indexul clasei (0 pentru sănătos, 1 pentru diabetic).
- p_{mc} : Proportia instanțelor aparținând clasei c în nodul m .

Rezultatul este un set de reguli vizualizabile, direct inteligibile de către medici. Principala limitare a DT este varianța ridicată: modificări minore ale datelor de antrenare pot produce structuri de arbori foarte diferite, ceea ce duce la predicții instabile pe date noi.




Fig. 1. [10] Arbore de Decizie generat pe setul PIDD. Se observă structura de tip „white-box”, unde atributul *Glucose* acționează ca nod rădăcină confirmând că aceasta este trăsătura cu cel mai mare câștig informațional în predicția diabetului, iar divizările succesive formează reguli decizionale clare.

4.3. Random Forest

Random Forest (RF), introdus de Breiman [2], rezolvă problema varianței ridicate a DT prin construirea unui ansamblu de B arbori independenți. Fiecare arbore este antrenat pe un eșantion diferit din setul de antrenare și consideră doar un subset aleator de atribute la fiecare divizare. Predicția finală a ansamblului se obține prin vot majoritar [2]:

$$\hat{y} = \text{mod}\{h_b(\mathbf{x}), b = 1, \dots, B\} \quad (3)$$

- $\hat{y}$: Clasa finală prezisă de ansamblu.
- mod : Selectează valoarea cea mai frecventă (modul statistic).
- $h_b(\mathbf{x})$: Predicția individuală a arborelui b pentru datele de intrare $\mathbf{x}$.
- B : Numărul total de arbori din „pădure”.

Deoarece arborii sunt independenți și decorelați, erorile individuale tind să se anuleze reciproc, reducând varianța fără a crește bias-ul. În plus, RF oferă implicit o măsură a importanței variabilelor (Feature Importance), calculată prin scăderea medie a unei metrice de impuritate (precum indexul Gini sau Entropia / Câștigul de Informație) pe întregul ansamblu [10].

4.4. Metrici de Performanță

Pentru a evalua obiectiv acești algoritmi, se utilizează metrici derivate din matricea de confuzie. Aceasta este un instrument tabelar care compară predicțiile modelului cu realitatea clinică, permițând vizualizarea directă a tipurilor de erori (Tabelul 2).

Table 2. Matricea de Confuzie pentru diagnosticul diabetului

		Clasa Prezisă	
		Diabetic (1)	Sănătos (0)
Clasa Reală	Diabetic (1)	Adevărat Pozitiv (TP)	Fals Negativ (FN)
	Sănătos (0)	Fals Pozitiv (FP)	Adevărat Negativ (TN)

Consecințele clinice ale predicțiilor:
TP: Pacient diabetic depistat corect
FN: Pacient diabetic ratat.
FP: Pacient sănătos este marcat ca suspect.
TN: Pacient sănătos depistat corect.

Table 3. Metricile de evaluare a performanței clasificatorilor

Metrică	Formulă	Relevanță Clinică
Accuracy	$\frac{TP+TN}{TP+TN+FP+FN}$	Proporția totală de predicții corecte.
Precision	$\frac{TP}{TP+FP}$	Probabilitatea ca un pacient prezis diabetic să fie cu adevărat bolnav.
Recall	$\frac{TP}{TP+FN}$	Prioritară: Capacitatea de a nu rata pacienții bolnavi (minimizează FN).
F1-Score	$2 \cdot \frac{Precision \cdot Recall}{Precision+Recall}$	Media armonică între precizie și recall.

5. Rezultate Recente în Literatură

5.1. Sisodia (2018) și Shafi & Ansari (2021)

Studii precum cele realizate de Sisodia [8] și ulterior reconfirmate de Shafi și Ansari [7] au stabilit performanța a trei algoritmi clasici: Naive Bayes, Decision Tree și Support Vector Machine (SVM), fără a implementa o preprocesare a datelor. Rezultatele obținute au fost similare: algoritmul Naive Bayes a obținut cea mai mare acuratețe (76.30% la Sisodia, respectiv 74.28% la Shafi), urmat de Decision Tree (73.82%, respectiv 71.81%), și de SVM cu cea mai slabă performanță (65.10%, respectiv 63.10%).

5.2. Zou et al. (2018)

Zou et al. [10] au realizat un studiu comparativ între Random Forest (RF), Decision Tree (J48) și o Rețea Neurală evaluând performanța pe setul de date PIDD. Folosind 5-fold cross-validation, performanța algoritmului Random Forest utilizând toate atributele a fost 76.04%. Totodată, rețeaua neuronală a atins o acuratețe mai bună, de 76.67% pe același set. O concluzie esențială raportată în studiu este validarea nivelului de glucoză ca fiind nodul rădăcină în toți arborii de decizie formați, ceea ce subliniază că acesta posedă cel mai mare câștig de informație (information gain) și rămâne cel mai relevant predictor clinic.

5.3. Butt et al. (2021)

Butt et al. [3] au îmbunătățit rezultatele pe setul PIDD propunând un pipeline bazat pe rețele neuronale optimizate. Utilizând o 10-fold cross-validation, o arhitectură Multi-Layer Perceptron (MLP) a atins o acuratețe superioară clasicatorilor clasici, de 86.08%. De asemenea, pentru a prezice dinamic nivelul de glucoză și incidența pe termen lung a bolii, autorii au aplicat o rețea recurentă Long Short-Term Memory (LSTM), cu ajutorul căreia au obținut o acuratețe predictivă remarcabilă de 87.26%. În ciuda rezultatelor bune, lumea medicală trebuie să fie reticentă în luarea deciziilor folosind aceste metode din pricina lipsei de interpretabilitate, deoarece rețelele neuronale profunde nu permit medicilor să înțeleagă cauzalitatea din spatele unui diagnostic.

5.4. Sahebbonar et al. (2022)

Sahebbonar et al. [6] oferă o perspectivă valoroasă printr-o evaluare clinică aplicată pe o populație externă – Forțele Terestre ale Armatei din Iran. Studiul abordează o prevalență extrem de mică a diabetului (doar 3% din cei 3.144 de subiecți incluși). Pentru rezolvarea dezechilibrului extrem s-a folosit tehnica SMOTE, aplicată pe o împărțire a datelor de 70/30, urmată 10-fold cross-validation pe setul de training [6]. Performanța modelului Random Forest (cu 1000 de arbori) a atins un AUC de 0.971 și o acuratețe globală de 94.40%. Deși extrem de performantă, generalizarea este limitată de tipul populației militare studiate, aceasta fiind în general mai sănătoasă.

5.5. DiabetesNet — Zhang et al. (2024)

Acest model se bazează pe o arhitectură Deep Learning BPNN (Back Propagation Neural Network) cu trei straturi ascunse de neuroni (64-32-16) și mecanisme de normalizare (Batch Normalization). Evaluat pe setul PIDD cu un raport de split 80/20 combinat cu 5-fold cross-validation, modelul a stabilit o acuratețe de 89.81%. Principala limitare constă în strategia de preprocesare: tehnica undersampling pentru echilibrarea claselor. În plus, natura „black-box” a acestui model scade transparența medicală necesară adoptării unor decizii clinice.

5.6. Bhatta & Husain (2026)

Bhatta și Husain [1] evaluează comparativ patru algoritmi pe setul PIDD: Random Forest, Decision Tree, Naive Bayes și Logistic Regression. Metodologia include preprocesarea datelor prin imputarea cu media aritmetică pentru valorile lipsă, eliminarea valorilor extreme prin metoda IQR, standardizare/normalizare, reducerea dimensionalității prin Principal Component Analysis (PCA), un split 80/20 și validare cu 10-fold cross-validation. Nu s-a aplicat nicio tehnică de echilibrare a claselor, ceea ce a limitat Recall-ul tuturor modelelor.

Table 4. Comparția rezultatelor din literatură pentru predicția diabetului.

Studiu	Dataset	Cel mai bun Model	Acc.	Recall	Echilibrare	Split / CV
Sisodia et al. (2018) [8]	PIDD	Naive Bayes	76.3%	0.763	Nu	10-fold
Shafi & Ansari (2021) [7]	PIDD	Naive Bayes	74.3%	0.761	Nu	10-fold
Zou et al. (2018) [10]	PIDD	Rețea Neuronală	76.6%	0.78	Nu	5-fold
Butt et al. (2021) [3]	PIDD	LSTM	87.2%	0.85	Nu	10-fold
Bhatta & Husain (2026) [1]	PIDD	Random Forest	77.49%	0.595	Nu	80/20 + 10-fold
Sahebbonar et al. (2022) [6]	Militar	RF + SMOTE	94.4%	1.000	SMOTE	70/30 + 10-fold
Zhang et al. (2024) [9]	PIDD	BPNN	89.8%	0.893	UnderSampling	80/20 + 5-fold

6. Discuții

6.1. Superioritatea Random Forest

Rezultatele agregate concluzionează ca algoritmul Random Forest depășește ceilalți algoritmi de clasificare. Acuratețea variază între 76.04% (fără preprocesare, Zou et al. [10]) și 94.40% (cu SMOTE, Sahenhonar et al. [6]), în funcție de calitatea preprocesării și a echilibrării datelor. Superioritatea RF este dată prin mecanismul său de ansamblu bazată pe principiul Bagging (Bootstrap Aggregating). Spre deosebire de un arbore de decizie singular, care este predispus la overfitting, RF construiește o multitudine de arbori decorrelați prin selectarea aleatorie a unui subset de atribute la fiecare divizare reducând varianza modelului prin agregarea predicțiilor individuale.

6.2. Impactul Critic al Echilibrării Claselor asupra Recall-ului

Una dintre cele mai importante concluzii ale acestei analize este rolul determinant al tehnicii de echilibrare a claselor asupra metricii Recall, aceasta fiind indicatorul cel mai relevant în contextul medical pentru minimizarea cazurilor de Fals Negativ. Compararea directă a studiilor ilustrează dramatic acest impact:

- Studiile fără echilibrare a claselor ([1],[8], [7], [10]) obțin Recall-uri între 0.595 și 0.78, adică 20–40% din pacienții diabetici rămân nedetectați.
- Sahebbonar et al. [6], aplicând SMOTE pe un set cu dezechilibru extrem (3% incidență), obțin un Recall perfect de 1.000 cu RF, eliminând complet erorile fals-negative.
- DiabetesNet [9], folosind undersampling, atinge un Recall de 0.893 — performanță remarcabilă, dar obținută cu pierderea a 232 de înregistrări valide.

6.3. Tradeoff-ul dintre Acuratețe și Interpretabilitate

Abordările de tip deep learning (MLP, LSTM, BPNN) ating cele mai mari acuratețe pe setul PIDD (86.08%–89.81%), depășind clasificatorii clasici. Cu toate acestea, aceste modele prezintă două dezavantaje fundamentale pentru adopția clinică:

- Natura „black-box”: Un model BPNN cu 3 straturi ascunse (64-32-16 neuroni) nu poate explica medicului de ce a clasificat un pacient ca diabetic.
- Riscul de overfitting: Pe seturi de date mici (768 instanțe), modelele complexe pot memoriza zgomotul din datele de antrenare, reducând generalizarea pe date clinice reale.

6.4. Compararea Strategiilor de Preprocesare

- Imputarea cu media vs. mediană: Bhatta & Husain [1] și Hasan et.al [5] utilizează media aritmetică, metodă vulnerabilă la valorile extreme din distribuțiile asimetrice (ex. insulina cu min 0 - max 846 $\mu\text{U/ml}$). Prezența lucrare propune imputarea cu mediană, mai robustă statistic, alegerea unei valori dintr-un set ordonat poate fi mai avantajoasă decât creșterea sintetică a unei valori.

7. Concluzii și Direcții viitoare

7.1. Concluzii

Prezența lucrare a realizat o analiză comparativă cuprinzătoare a metodelor de clasificare prin învățare automată pentru predicția riscului de diabet, cu focusul pe setul de date Pima Indians Diabetes Database (PIDD). Au fost evaluați trei algoritmi interpretabili de tip „white-box”: Regresia Logistică, Arborele de Decizie și Random Forest, cu accent pe tehnicile de preprocesare (imputare cu mediană, SMOTE) și pe metrica Recall ca indicator prioritar de performanță clinică.

- **Random Forest** este algoritmul cu performanța per-total cea mai bună dintre clasificatorii clasici
- **Tehnica SMOTE** este esențială pentru aplicațiile medicale. Studiile care o aplică obțin un Recall semnificativ mai mare, reducând riscul de rezultate fals-negative care pot pune în pericol viața pacienților.
- **Glucoza plasmatică** este cel mai important predictor al diabetului în toate studiile analizate, acționând ca nod rădăcină în toți arborii de decizie
- **Siguranță medicală** (LR, DT, RF) ajută cadrele medicale prin interpretabilitatea pe care o oferă, în ciuda unor scoruri de acuratețe ușor mai mici.

7.2. Direcții Viitoare

- **Documentarea Integrării Explainable AI (XAI):** utilizarea tehnicilor de interpretare a modelelor complexe, precum SHAP(SHapley Additive exPlanations) sau LIME(Interpretable Model-agnostic Explanations) pentru arhitecturile deep-learning (ex. BPNN, LSTM) oferind medicilor explicații vizuale ale predicțiilor cu acuratețe ridicată
- **Date Multimodale:**
 - *Imagistică Medicală:* Utilizarea tehnicilor de Computer Vision pentru analiza fotografiilor clinice identificând semne timpurii ale bolii.
 - *OCR și NLP:* Implementarea unui modul de OCR pentru extragerea automată a datelor din analize scanate, urmată de procesarea limbajului natural (NLP) pentru a converti observațiile textuale ale medicilor în variabile de intrare pentru modelul de predicție.

Declarație privind utilizarea tehnologiilor de tip IA

În timpul pregătirii acestei lucrări, autorul a folosit instrumentul Gemini pentru a îmbunătăți limbajul și lizibilitatea lucrării. După utilizarea acestui instrument/serviciu, autorul a revizuit și editat conținutul după cum a fost necesar și își asumă întreaga responsabilitate pentru conținutul publicației.

References

- [1] Bhatta, R., Husain, A., 2026. Early prediction of type 2 diabetes using supervised machine learning algorithm. International Journal of Advanced Research in Engineering and Technology (IJARET) 17, 60–73. doi:10.34218/IJARET_17_01_003.
- [2] Breiman, L., 2001. Random forests. Machine Learning 45, 5–32. doi:10.1023/A:1010933404324.
- [3] Butt, U.M., Letchmunan, S., Ali, M., Hassan, F.H., Baqir, A., Sherazi, H.H.R., 2021. Machine learning based diabetes classification and prediction for healthcare applications. Journal of Healthcare Engineering 2021, 9930985. doi:10.1155/2021/9930985.
- [4] Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P., 2002. Smote: Synthetic minority over-sampling technique. Journal of Artificial Intelligence Research 16, 321–357. doi:10.1613/jair.953.
- [5] Hasan, M.K., Alam, M.A., Das, D., Hossain, E., Hasan, M., 2020. Diabetes prediction using ensembling of different machine learning classifiers. IEEE Access 8, 76516–76531. doi:10.1109/ACCESS.2020.2989857.
- [6] Sahebbonar, M., Gholampour Dehaki, M., Kazemi-Galougahi, M.H., Soleiman-Meigooni, S., 2022. A comparison of three research methods: Logistic regression, decision tree, and random forest to reveal association of type 2 diabetes with risk factors and classify subjects in a military population. Journal of Archives of Military Medicine 10, e118525. doi:10.5812/jamm-118525.
- [7] Shafi, S., Ansari, M., 2021. Early prediction of diabetes disease & classification of algorithms using machine learning approach. Materials Today: Proceedings doi:10.2139/ssrn.3852590.
- [8] Sisodia, D., Sisodia, D.S., 2018. Prediction of diabetes using classification algorithms. Procedia Computer Science 132, 1578–1585. doi:10.1016/j.procs.2018.05.122.
- [9] Zhang, Z., Ahmed, K.A., Hasan, M.R., Gedeon, T., Hossain, M.Z., 2024. A deep learning approach to diabetes diagnosis, in: Recent Challenges in Intelligent Information and Database Systems. ACIIDS 2024, Springer, Singapore. pp. 87–99. doi:10.1007/978-981-97-5937-8_8.
- [10] Zou, Q., Qu, K., Luo, Y., Yin, D., Ju, Y., Tang, H., 2018. Predicting diabetes mellitus with machine learning techniques. Frontiers in Genetics 9, 515. doi:10.3389/fgene.2018.00515.