

Sistem Inteligent pentru Predicția Riscului de Diabet

Context: Diabetul zaharat reprezintă o problemă majoră de sănătate publică, cu o morbiditate în creștere ce necesită soluții de diagnosticare timpurie non-invazive. Scopul acestei lucrări este evaluarea comparativă a algoritmilor de Machine Learning pentru a identifica cea mai fiabilă metodă de screening clinic.

Studiul utilizează setul de date *Pima Indians Diabetes Database* (PIDD), vizând 768 de pacienți de origine amerindiană. Pilonul central al lucrării îl reprezintă etapele critice de preprocesare:

- **Tratarea valorilor nule: Imputarea cu Mediana:** Se argumentează că mediana este mai robustă decât media aritmetică deoarece nu este influențată de valori extreme.
- **Echilibrarea claselor:** Se argumentează superioritatea tehnicii **SMOTE** (Synthetic Minority Over-sampling Technique) față de sub-eșantionare (undersampling), deoarece SMOTE generează date sintetice în spațiul trăsăturilor fără a elimina date reale.

Au fost selectate modele de tip „white-box” pentru a asigura transparența necesară în domeniul medical:

- **Regresia Logistică:** Utilă pentru identificarea factorilor de risc individuali (glucosă, vârstă, indicele de masă corporală, etc.).
- **Arborele de Decizie:** Permite vizualizarea regulilor de tip „if-then”, confirmând glucoza ca fiind cel mai relevant predictor clinic.
- **Random Forest :** Identificat ca fiind cel mai performant clasificator clasic datorită capacității de a reduce overfittingul și varianța prin agregarea mai multor arbori decorelați.

Table 4. Comparația rezultatelor din literatură pentru predicția diabetului.

Studiu	Dataset	Cel mai bun Model	Acc.	Recall	Echilibrare	Split / CV
Sisodia et al. (2018) [8]	PIDD	Naive Bayes	76.3%	0.763	Nu	10-fold
Shafi & Ansari (2021) [7]	PIDD	Naive Bayes	74.3%	0.761	Nu	10-fold
Zou et al. (2018) [10]	PIDD	Rețea Neuronală	76.6%	0.78	Nu	5-fold
Butt et al. (2021) [3]	PIDD	LSTM	87.2%	0.85	Nu	10-fold
Bhatta & Husain (2026) [1]	PIDD	Random Forest	77.49%	0.595	Nu	80/20 + 10-fold
Sahebbonar et al. (2022) [6]	Militar	RF + SMOTE	94.4%	1.000	SMOTE	70/30 + 10-fold
Zhang et al. (2024) [9]	PIDD	BPNN	89.8%	0.893	UnderSampling	80/20 + 5-fold

Analiza literaturii indică faptul că, deși modelele de Deep Learning ating acurateți ridicate (ex. BPNN - 89.81%), natura lor "black-box" le face dificil de adoptat în clinici. Această lucrare pune accentul pe metrica **Recall**, demonstrând că aplicarea SMOTE poate ridica acest indicator până la valori optime, minimizând cazurile de pacienți bolnavi nediagnosticați (fals-negativi). Concluzia principală subliniază că **nivelul glucozei** rămâne cel mai relevant predictor clinic.